

מבוא לבניה מלאכותית - תרגול 1.

רגב יחזקאל אימרה.

23 באוקטובר 2025

יש הרבה סוגי למידה בעולם, הנה חלקם:

1. למידה מפקחת: לכל דגימה יש את התווית שלה (label).
(א) סיווג: חיזוי קטגוריות.
(ב) רגרסיה: חיזוי ערך רציף.
 2. למידה לא מפקחת: יש דגימות, אין תוויות.
(א) אשכול: חלוקת דגימות לקבוצות.
(ב) הורדת מימדים: הפתחת כמות הפיצ'רים של המודל.
(ג) זיהוי אנומליות: גילוי דגימות חריגות מבין סך כל הדגימות.
 3. למידה באמצעות חיזוקים: המודל לומד דרך ניסוי וטעייה. המודל מבצע פעולות ומקבל חיזוקים (חיוביים או שליליים) ומשפר את המדיניות שלו.
 4. למידה מונחית עצמית: המערכת מייצרת לעצמה תוויות מתוך הנתונים כדי ללמוד ייצוגים יותר טובים.
 5. למידה גנרטיבית: המערכת מייצרת נתונים חדשים הדומים לנתונים המקוריים עליהם אומנה.
- בקורס הזה נתמקד בעיקר בלמידה מפקחת. למעוניינים, המחלקה למתמטיקה מציעה קורס בלמידה לא מפקחת, והמחלקה למדעי המחשב מציעה קורסים בשער סוגי הלמידה.

חלק I

מודלי סיווג.

1 הגדרות כלליות.

לאילו שלא זוכרים, בלמידה מפקחת יש שתי נישות מרכזיות: קלסיפיקציה ורגרסיה.

הגדרה 1.1. מודל **קלסיפיקציה** / **סיווג** הוא מודל שמטרתו לנבא קטגוריה (label) מתוך קבוצה **סופית** של מחלקות.

דוגמה 2.1. דוגמאות למודל קלסיפיקציה:

1. האם מייל הוא ספאם או לא ספאם.
2. האם מטופל הוא חולה או בריא.
3. האם תמונה היא של כלב, חתול, או ארנב.

איך עובד מודל סיווג?

(1) **המטרה של מודל סיווג:**

מודל סיווג בא מנקודת הנחה שאם יש לי קבוצת דגימות / תצפיות X וקבוצת תיוגים Y , אזי קיימת פונקציה כלשהי $f : X \rightarrow Y$ המקיימת $f(x_i) = y_i$. המטרה של המודל היא ללמוד את הקשר בין דגימה x_i והתיוג שלה y_i , כדי שכשנדגום דגימה חדשה $\hat{x}$, המודל יחזה מה התיוג המתאים $\hat{y}$.

(2) **תהליך הלמידה:**

במהלך האימון של המודל אנחנו מכניסים לו זוגות סדורים (x_i, y_i) , והמודל מחפש דפוסים שמחברים בין הקלט x_i והפלט y_i . המודל מתאים את הפרמטרים שלו כדי להקטין את כמות הטעויות שהוא עושה.

(3) **הרעיון:**

מודל בכללי רוצה להחזיר את התיוג הכי סביר. לכן הוא מחשב את $\mathbb{P}(c_i|x)$ ויחזיר את

$$\hat{c} = \arg \max_i \mathbb{P}(c_i|x)$$

כלומר המחלקה שהמודל יחזה היא זו שהכי גיונית לתצפית.

(4) **תהליך האימון (אפשר לדלג בתרגול 1):**

כשמאמנים את המסווג, המטרה היא למצוא פרמטרים θ שיגרמו לתצפיות להיות הכי סבירות. המודל מנסה למקסם את הנראות של התחזיות שלו:

$$L(\theta) = \mathbb{P}(y_1, y_2, \dots, y_d | x_1, x_2, \dots, x_d; \theta)$$

אם אנחנו נניח שהדגימות i.i.d. (תמיד נכון אלא אם נאמר אחרת) נקבל

$$L(\theta) = \prod_{i=1}^d \mathbb{P}(y_i | x_i; \theta)$$

ניקח לוגריתם משני הצדדים ונקבל

$$\log L(\theta) = \sum_{i=1}^d \log \mathbb{P}(y_i | x_i; \theta)$$

וכיוון שפונקציית ה- $\log$ עולה, למקסם את הנראות שקול למקסם את לוג הנראות, כלומר אנחנו מחפשים


$$\hat{\theta} = \arg \max_{\theta} \log L(\theta)$$

הבעיה הנ"ל שקולה ללמצוא את

$$\mathcal{L}(\theta) = - \sum_{i=1}^d \log \mathbb{P}(y_i | x_i; \theta)$$

2 סיווג בייסיאני נאיבי - Naive Bayes.

מוטיבציה: נניח ועכשיו יש לי שני פיצ'רים X_1, X_2 שקובעים לי האם נקודה (x_1, x_2) היא אדומה או כחולה



נניח ויש לי 50 דגימות כאלו עם 20 נקודות כחולות ו-30 נקודות אדומות. לכן אפשר לומר שהפריור שלי על הצבע שלנקודה חדשה יהיה

$$Prior(Blue) = 0.4$$

$$Prior(Red) = 0.6$$

לכן רק עם פריור לבד לא נגיע רחוק כי נסווג כל נקודה חדשה כתור נקודה אדומה?

מה הבעיה? לא לקחנו בחשבון את הפיצ'רים X_1, X_2 .

הרעיון המרכזי של Naive Bayes זה שבהינתן קלט $x = (x_1, x_2, \dots, x_d)$ וקבוצת מחלקות $C = \{C_1, \dots, C_k\}$ אנחנו רוצים לבחור ל- x את הסיווג $\hat{c} \in C$ שימקסם את ההסתברות המותנית $\mathbb{P}(\hat{c}|x)$, כלומר $\hat{c} = \arg \max_i \mathbb{P}(c_i|x)$

הצעה 1.2. אלגוריתם מסווג נאיבי.

תזכורת: אנחנו רוצים למצוא את $\mathbb{P}(c_i|x)$. נוסחאת בייס אופרת לנו כי

$$\mathbb{P}(c_i|x) = \frac{\mathbb{P}(x|c_i)\mathbb{P}(c_i)}{\mathbb{P}(x)}$$

כאשר:

- $\mathbb{P}(c_i)$ זה הפריור שלנו - מה הסיכויים המחלקה ה- i להופיע.
 - $\mathbb{P}(x|c_i)$ זה הנראות של התצפית x בהינתן שהיא במחלקה c_i - כמה סביר לראות את x בהינתן שהדגימה במחלקה c_i .
 - $\mathbb{P}(x)$ - ההסתברות לדגימה x .
- נציב את נוסחאת בייס במטרה שלנו ונקבל שהמחלקה שהמודל יחזה היא

$$\begin{aligned}\hat{c} &= \arg \max_i \mathbb{P}(c_i|x) \\ &= \arg \max_i \frac{\mathbb{P}(x|c_i)\mathbb{P}(c_i)}{\mathbb{P}(x)} \\ &= \arg \max_i \mathbb{P}(x|c_i)\mathbb{P}(c_i)\end{aligned}$$

כי הדגימות הן שוות התפלגות. הבעיה עכשיו היא לחשב את $\mathbb{P}(x|c_i)$. למה? כי אנחנו צריכים לחשב $\mathbb{P}(x_1, x_2, \dots, x_d|c_i)$ ואם נגיד לכל פיצ'ר x_i יש m ערכים אפשריים אזי גודל מרחב במדגם יהיה m^d . כיוון שאין לנו מספיק דאטה אף פעם לחשב את זה, נצטרך להיות יצירתיים. למה קוראים למסווג נאיבי? כי n מסווג בייסיאני מניח אי תלות של הפיצ'רים בהינתן c , כלומר הוא מניח כי

$$\mathbb{P}(x|c_i) = \mathbb{P}(x_1, x_2, \dots, x_d|c) = \prod_{i=1}^d \mathbb{P}(x_i|c)$$

זה באמת נאיבי כי לעיתים רחוקות זה באמת נכון (ניתן לחשוב בקלות על דוגמאות בהן הנחה זו לא נכונה) כלומר סה"כ ההחלטה $\hat{c} = \arg \max_i \mathbb{P}(c_i|x)$ הופכת להיות

$$\hat{c} = \arg \max_j \mathbb{P}(c_j) \prod_{i=1}^d \mathbb{P}(x_i|c_j)$$

תהליך הלמידה גם פשוט מאוד, שכן אפשר לקחת

$$\mathbb{P}(c_i) = \frac{\text{count}(c_i)}{N}, \quad \mathbb{P}(x_i|c_j) = \frac{\text{count}(x_i, c_j)}{\text{count}(c_j)}$$

כאשר:

- $\text{count}(c_j)$ זה כמה פעמים יש בדאטה שלנו דגימה עם תיוג c_j .
- $\text{count}(x_i, c_j)$ זה כמה פעמים הפיצ'ר x_i הופיע עם תיוג c_j .
- $\text{count}(x)$ זה כמה פעמים שהדגימה x הופיעה בדאטה שלנו.
- N זה כמות הדגימות שיש לנו.

דוגמה 2.2. אספנו נתונים מעשרה שכנים שלנו וריכזנו אותם בטבלה

dataset				label
id	Age	Hobby	Weather	Buy Computer?
1	Young	Sport	Cold	"Yes"
2	Young	Sport	Cold	"Yes"
3	Young	Sport	Cold	"No"
4	Old	Sport	Hot	"Yes"
5	Old	Sport	Hot	"Yes"
6	Old	Paint	Hot	"No"
7	Old	Paint	Cold	"Yes"
8	Old	Paint	Cold	"Yes"
9	Young	Paint	Hot	"No"
10	Young	Sport	Hot	"No"

ואנחנו רוצים לדעת האם כדאי לנו לקנות מחשב חדש, כשהדגימה שלנו היא Young, Paint, Cold. לכן אנחנו צריכים לחשב את

$$\mathbb{P}(Yes|Young, Paint, Cold)$$

נחשב:

$$\begin{aligned}\mathbb{P}(Yes|Young, Paint, Cold) &\stackrel{*}{=} \frac{\mathbb{P}(Young, Paint, Cold|Yes) \mathbb{P}(Yes)}{\mathbb{P}(Young, Paint, Cold)} \\ &\stackrel{**}{=} \frac{\mathbb{P}(Age = Young|Yes) \mathbb{P}(Hobby = Paint|Yes) \mathbb{P}(Weather = cold|Yes) \mathbb{P}(Yes)}{\mathbb{P}(Young, Paint, Cold)}\end{aligned}$$

* לפי חוק בייס.

** לפי הנחת Naive Bayes.

צריך לחשב כל חלק בנפרד:

$$\begin{aligned}\mathbb{P}(Age = Young|Yes) &= \frac{\mathbb{P}(Age = Young, Yes)}{\mathbb{P}(Yes)} = \frac{\frac{2}{10}}{\frac{6}{10}} = \frac{1}{3} \\ \mathbb{P}(Hobby = Paint|Yes) &= \frac{\mathbb{P}(Hobby = Paint, Yes)}{\mathbb{P}(Yes)} = \frac{\frac{2}{10}}{\frac{6}{10}} = \frac{1}{3} \\ \mathbb{P}(Weather = cold|Yes) &= \frac{\mathbb{P}(Weather = cold, Yes)}{\mathbb{P}(Yes)} = \frac{\frac{4}{10}}{\frac{6}{10}} = \frac{2}{3}\end{aligned}$$

כלומר

$$\mathbb{P}(Young, Paint, Cold|Yes) = \frac{2}{27}$$

וכדי לחשב את המכנה נצטרך להשתמש בנוסחאות ההסתברות השלמה

$$\mathbb{P}(Young, Paint, Cold) = \mathbb{P}(Young, Paint, Cold|Yes)\mathbb{P}(Yes) + \mathbb{P}(Young, Paint, Cold|No)\mathbb{P}(No)$$

ומחישוב דומה

$$\mathbb{P}(Young, Paint, Cold|No) = \frac{3}{32}$$

נציב הכל ונקבל

$$\mathbb{P}(Yes|Young, Paint, Cold) = \frac{\frac{6}{10} \cdot \frac{2}{27}}{\frac{6}{10} \cdot \frac{2}{27} + \frac{4}{10} \cdot \frac{3}{32}} = 0.542$$

ולכן ההסתברות של המאורע המשלים תהיה

$$\mathbb{P}(No|Young, Paint, Cold) = 1 - 0.542 = 0.458$$

ולכן אנחנו כן נקנה מחשב חדש.

3 שיטות להערכת מודל סיווג.

אחרי האימון, המודל יודע איך לחשב $\hat{c} = \arg \max_j \mathbb{P}(c_j) \prod_{i=1}^n \mathbb{P}(x_i|c_j)$ לכל דגימה חדשה.

כדי להעריך את המודל, נרצה לענות על השאלה "כמה טוב התיוגים הללו תואמים את התיוגים האמיתיים". כדי לענות על השאלה הזו. מן הסתם נצטרך לשמור חלק מהדאטה שלנו בצד, על מנת שיהיו לנו דגימות חדשות שאנחנו יודעים את התיוגים שלהם. בדרך כלל נחלק את הדאטה שלנו ל-80% קבוצת אימון (train set) ו-20% קבוצת מבחן (test set).

כאן נצטרך לפצל את השיטה שאנחנו מעריכים את המודל, תלוי בגודל קבוצת התיוגים C .

3.1 סיווג בינארי.

1.3 הגדרה. מודל סיווג בינארי, הוא מודל סיווג אשר קבוצת התיוגים שלו היא מגודל 2.

2.3 דוגמה. דוגמאות לסיווג בינארי:

1. יום גשום מול יום שמש.

2. מייל ספאם או מייל לא ספאם.

3. כלב או חתול.

3.3 הערה. שימו לב שהתיוגים לא חייבים להיות משלימים אחד של השני כמו ב"ספאם" מול "לא ספאם", התיוגים יכולים להיות תת קבוצה של קבוצה גדולה יותר, כמו בסיווג בינארי של "כלב" מול "חתול". כולנו יודעים שיש עוד חיות בעולם חוץ מכלב וחתול, פשוט המודל שלנו לא ידע את זה לעולם. אם נזין לו רק תמונות של כלבים וחתולים באימון ולאחר מכן נזין לו תמונה של חמור, התוצאה לא תהיה חמור כי הוא לא יודע שיש דבר כזה. התוצאה תהיה כלב או חתול, תלוי בפרמטרים של המודל לאחר האימון. אם נכניס לו תחת תיוגים של "כלב" רק תמונות של כלבים, ואילו לעומת זאת תחת תיוג של "חתול" נכניס לו תמונות של חמור וחתול, אזי כשנכניס למודל המאומן שלנו תמונה של חמור הוא יוציא לנו תיוג של חתול.

מה שנחו בסיווג בינארי זה שאני יודע שאם x_i לא סווג להיות y_1 אז הוא סווג להיות y_2 , כלומר צריך לחשב רק הסתברות אחת $\mathbb{P}(y_1|x)$ כי $\mathbb{P}(y_2|x) = 1 - \mathbb{P}(y_1|x)$.

לעומת זו בסיווג עם יותר מ-2 תוויות נצטרך להיות יותר מתוחכמים - בהמשך.

הגדרה 4.3. כשיש לנו דגימה x ואת התיוג האמיתי שלה $y \in \{y_1, y_2\}$, נוציא מהמודל את התיוג שלה לפיו, $\hat{y}$. כאן תיוג 1 זה תיוג חיובי ותיוג 0 זה תיוג שלילי. לפיכך, אם:

- $y = 1, \hat{y} = 1$ נאמר שהדגימה x היא True Positive ונסמן בקצרה (TP).
- $y = 1, \hat{y} = 0$ נאמר שהדגימה x היא False Negative ונסמן בקצרה (FN).
- $y = 0, \hat{y} = 1$ נאמר שהדגימה x היא False Positive ונסמן בקצרה (FP).
- $y = 1, \hat{y} = 1$ נאמר שהדגימה x היא True Negative ונסמן בקצרה (TN).

נסכם הכל בטבלה הבאה:

	Predicted Positive	Predicted Negative
Actual Positive	True Positive (TP)	False Negative (FN)
Actual Negative	False Positive (FP)	True Negative (TN)

ההגדרה לא מושלמת, לכן הדוגמה הבאה יכולה לעזור:

דוגמה 5.3. משה לוקח בדיקה שאומרת האם הוא חולה בקורונה. כאן דגימה חיובית זה שיש קורונה, ודגימה שלילית תהיה שאין לו קורונה.

אם הבדיקה אמרה שיש לו קורונה ובאמת יש לו קורונה, אז הוא TP .

אם הבדיקה אמרה שיש לו קורונה אבל אין לו קורונה, אז הוא FP .

אם הבדיקה אמרה שאין לו קורונה אבל יש לו קורונה, אז הוא FN .

אם הבדיקה אמרה שאין לו קורונה ובאמת אין לו קורונה, אז הוא TN .

הצעה 6.3. יש לנו פגוון רחב של מדדי הערכת איכות לפיכך, סיווג בינארי, והם:

1. $Accuracy$: החלק היחסי של התחזיות הנכונות מתוך כלל הדגימות.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2. $Precision$: מבין כל התחזיות שסופנו חיוביות, כמה מהם באמת חיוביות

$$Precision = \frac{TP}{TP + FP}$$

3. TPR (Recall): מבין כל הדגימות החיוביות, כמה מהן המודל זיהה

$$TPR \setminus Recall = \frac{TP}{TP + FN}$$

4. : מבין כל הדגימות השליליות, כמה מהן המודל זיהה

$$TPR \setminus Recall = \frac{TP}{TP + FN}$$

5. ROC curve: עקומה המציגה את היחס בין TPR ל- FPR עבור כל ערכי הסף האפשריים של ההחלטה.

6. AUC : השטח מתחת לעקומת ה- ROC .

הערה 7.3. בהינתן מודל סיווג בינארי עם $AUC < \frac{1}{2}$, נסו לחשוב למה אומרים שמודל יותר טוב הוא אחד שמנחש ברנדומליות 0 או 1 $\mathbb{P}(0) = 0.5$ $\mathbb{P}(1) = 0.5$.