

מבוא לבנינה מלאכותית - תרגול 3.

רגב יחזקאל אימרה.

23 בנובמבר 2025

1 רגרסיה לוגיסטית.

בשונה מרגרסיה לינארית/ פולינומאלית שרוצות לחזות ערך רציף, כאן אנחנו מעוניינים לחזות האם משהו קורה או לא קורה.

הגדרה 1.1. מודל **קלסיפיקציה** / **סיווג** הוא מודל שמטרתו לנבא קטגוריה (*label*) מתוך קבוצה **סופית** של מחלקות.

עד עכשיו היה לנו מודל מהצורה

$$\hat{y} = w^T x + b$$

ולכל דגימה x חזינו ערך $y \in \mathbb{R}$. בבעיית סיווג, יש לנו כמות סופית של מחלקות, $y \in \{c_1, c_2, \dots, c_k\}$, ולכל דגימה אני רוצה לחזות לאיזה מחלקה היא שייכת. לכן מודל רגרסיה לא יעבוד (גם כי מה זה אומר להיות בחלקה 6.5, וגם כי עבור ערך x ה- $\hat{y}$ שאנחנו חוזים יעבור את כל המחלקות?), ואנחנו נצטרך לפתח מודל אחר.

דוגמה 2.1. דוגמאות למודל קלסיפיקציה:

1. האם מייל הוא ספאם או לא ספאם.
 2. האם מטופל הוא חולה או בריא.
 3. האם תמונה היא של כלב, חתול, או ארנב.
 4. מי האדם שאנחנו רואים בתמונה.
 5. בהינתן ההתנהגות של האדם, לחזות איזה מזל הוא (טלה, שור, תאומים וכו').
- הרעיון: למודל יש הרבה מחשבות פנימיות ועמוקות, ובכללי הוא רוצה להחזיר את התשובה הכי הגיונית. במקרה שלנו, זה התיוג הכי סביר. לכן הוא מחשב את $\mathbb{P}(c_i|x)$ לכל מחלקה c_i ויחזיר את

$$\hat{c} = \arg \max_i \mathbb{P}(c_i|x)$$

כלומר המחלקה שהמודל יחזה היא זו שהכי הגיונית לתצפית. כשמאמנים את המסווג, המטרה היא למצוא פרמטרים θ שיגרמו לתצפיות להיות הכי סבירות.

כיום נעסוק בסיווג בינארי, כלומר כל קבוצת המחלקות שלי קורסת להיות $\{0, 1\}$.
סה"כ אנחנו רוצים פונקציה

$$p_\theta(x) = \mathbb{P}(Y = 1|x; \theta)$$

שתחזה לנו מה הסיכוי לסיווג 1 בהינתן הדגימה (והפרמטרים של המודל).

יש לנו כמה דרישות מהמודל:

1. $0 < p_\theta(x) < 1$ לכל דגימה x .
2. p_θ צריכה להיות חלקה וקלה לאינטוס (יחסית).
3. התלות ב- x צריכה להיות לינארית, כלומר משקולת w_j חיובית תדחוף לי ערכי x גבוהים לכיוון $p_\theta(x) = 1$, ומשקולת w_j שלילית תדחוף לי ערכי x גבוהים לכיוון $p_\theta(x) = 0$.

הגדרה 3.1. בהינתן כל הדרישות הנ"ל, פונקציה אחת שבאה לראש הוא פונקציית הסיגמואיד

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$


טענה 4.1. תכונות הסיגמואיד:

1. הטווח שלו הוא $\sigma : \mathbb{R} \rightarrow (0, 1)$.
2. פונקציה חלקה (כלומר $\sigma \in C^\infty$).
3. בהינתן $\sigma(z)$ עבור $z \in \mathbb{R}$, הנגזרת היא פשוט $\sigma'(z) = \sigma(z)(1 - \sigma(z))$.

לכן דרישות (1) ו-(2) מתקיימות, וכדי לקיים גם את דרישה (3) נגדיר את המודל שלנו להיות

$$p_{\theta}(x) = \sigma(w^T x + b)$$

הערה 5.1. כרגע $\mathbb{P}(Y = 1|x; \theta) = p_{\theta}(x)$, ולכן הסיכוי שהדגימה x תהיה במחלקה 0 הוא $\mathbb{P}(Y = 0|x; \theta) = 1 - p_{\theta}(x)$. למה סיגמואיד ולא פונקציה אחרת? סיגמואיד נראה ככה:



ספציפית לקחתי $y = \frac{1}{1+e^{-(6.4x-7)}}$. הרעיון הוא שאנחנו רוצים שככל ש- x קטן, שהסיכוי שלו להיות במחלקה 1 יקטן בהתאם.

לדוגמה, אם אני חוזה הצליח במבחן/ לא הצליח במבחן/ בשעות הלמידה שלו, הגיוני שהדגימות שבציר ה- x קרובות ל-0 (כלומר תלמיד למד ממש קצת) יהיו במחלקה 0 לעומת דגימות עם ערך x גבוה יותר שיהיו במחלקה 1 (כי תלמיד למד הרבה). כמובן גם שיכולים להיות תלמידים שלמדו קצת ועברו, ותלמידים שהשקיעו את חייהם בלמידה למבחן ונכשלו, ומה שטוב במודל הזה זה שהוא לא יושפע יותר מדי מהמיעוטים האלה. ככל שמישהו לומר יותר, ככה אנחנו מצפים שיצליח יותר. זה בדיוק מה שסיגמואיד אומר לנו, שככל ש- x גדול יותר (ו- w חיובי), נקבל שהערך y שלו (הסיכוי להיות במחלקה 1) גדול יותר.

שימו לב שאם אין לי הפרדה כלשהי בין המחלקות שלי (קורולציה נמוכה בין עובר/ נכשל כתלות בזמן הלמידה שלי) אז אין באמת סיגמואיד שיפריד לי בין המחלקות, לכן אנחנו מניחים שיש קורולציה כלשהי בין ה- x ל- y (כמו שהנחנו $y = w^T x + b$ ברגרסיה לינארית)

1.1 פונקציית loss?

להזכירכם, ברגרסיה לינארית $\hat{y} = w^T x + b$ היה לנו $\mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$ (ועוד $\lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$ לרגורליזציה), אבל זה בשביל רגרסיה לינארית, פה אנחנו ברגרסיה לוגיסטית, לכן צריך לחשוב על מה יהיה ה- $loss$ שלנו. באופן כללי, כל מודל מנסה למקסם את הנראות (בלעז, *likelihood*) של התחזיות שלו:

$$L(\theta) = \mathbb{P}(y_1, y_2, \dots, y_N | x_1, x_2, \dots, x_N; \theta)$$

(כאשר x_i הדגימה שלנו, y_i המחלקה שאליה סיווגנו את x_i , ו- N כמות הדגימות שלנו). אם אנחנו נניח שהדגימות i.i.d. (תמיד נכון אלא אם נאמר אחרת) נקבל

$$L(\theta) = \prod_{i=1}^N \mathbb{P}(y_i | x_i; \theta)$$

ניקח לוגריתם משני הצדדים ונקבל

$$\log L(\theta) = \sum_{i=1}^N \log \mathbb{P}(y_i | x_i; \theta)$$

וכיוון שפונקציית ה- $\log$ עולה, למקסם את הנראות שקול למקסם את לוג הנראות, כלומר אנחנו מחפשים

$$\hat{\theta} = \arg \max_{\theta} \log L(\theta)$$

הבעיה הנ"ל שקולה ללמזער את

$$\mathcal{L}(\theta) = - \sum_{i=1}^N \log \mathbb{P}(y_i | x_i; \theta)$$

עבור סיווג בינארי $y_i \in \{0, 1\}$ אפשר לכתוב $\mathbb{P}(y_i | x_i; \theta) = p_{\theta}(x_i)^{y_i} (1 - p_{\theta}(x_i))^{1-y_i}$ כי אם $y_i = 1$ אז נקבל $\mathbb{P}(y_i | x_i; \theta) = p_{\theta}(x_i)$ ואם $y_i = 0$ נקבל $\mathbb{P}(y_i | x_i; \theta) = 1 - p_{\theta}(x_i)$. מכאן נקבל

$$\mathcal{L}(\theta) = - \sum_{i=1}^N y_i \log p_{\theta}(x_i) + (1 - y_i) \log(1 - p_{\theta}(x_i))$$

הגדרה 6.1. אם נמצע את $\mathcal{L}$ נקבל את **הפסד האנטרופיה הצולבת המינימלית** (תרגום נואש מאנגלית - *Binary Cross - Entropy*)

$$BCE(\theta) = -\frac{1}{N} \sum_{i=1}^N y_i \log \sigma(w^T x + b) + (1 - y_i) \log(1 - \sigma(w^T x + b))$$

הערה 7.1. רק לוודא שאנחנו על אותו דף, $y_i \in \{0, 1\}$ (אפשר גם ± 1 אבל זה ידרוש קצת יותר חשיבה איך להגדיר את $\mathbb{P}(y_i|x_i; \theta)$ ככה), וכן $\sigma(w^T x + b) \in (0, 1)$

1.2 איך מאמנים?

פשוט, עם אלגוריתם GD . נחשב נגזרות חלקיות:
נסמן:

$$1. z_i = w^T x_i + b$$

$$2. p_i = p_\theta(x_i) = \sigma(z_i)$$

$$3. \ell_i(\theta) = -(y_i \log p_i + (1 - y_i) \log(1 - p_i))$$

לכן ה- $loss$ שלנו הופך להיות

$$\mathcal{L}(\theta) = \sum_{i=1}^N \ell_i(\theta)$$

נרצה לחשב את $\frac{\partial \mathcal{L}}{\partial w}, \frac{\partial \mathcal{L}}{\partial b}$. מכלל השרשרת:

$$\frac{\partial \mathcal{L}}{\partial w} = \sum_{i=1}^N \frac{\partial \ell_i}{\partial p_i} \frac{\partial p_i}{\partial z_i} \frac{\partial z_i}{\partial w}$$

$$\frac{\partial \mathcal{L}}{\partial b} = \sum_{i=1}^N \frac{\partial \ell_i}{\partial p_i} \frac{\partial p_i}{\partial z_i} \frac{\partial z_i}{\partial b}$$

נחשב:

$$\frac{\partial \ell_i}{\partial p_i} = -\frac{\partial}{\partial p_i} y_i \log p_i - \frac{\partial}{\partial p_i} (1 - y_i) \log(1 - p_i) = -\frac{y_i}{p_i} + \frac{1 - y_i}{1 - p_i} = \frac{p_i - y_i}{p_i(1 - p_i)}$$

בנוסף,

$$\frac{\partial p_i}{\partial z_i} = \frac{\partial}{\partial z_i} \sigma(z_i) = \sigma(z_i)(1 - \sigma(z_i)) = p_i(1 - p_i)$$

וכן

$$\begin{aligned} \frac{\partial z_i}{\partial w} &= \frac{\partial}{\partial w} (w^T x_i + b) = x_i \\ \frac{\partial z_i}{\partial b} &= \frac{\partial}{\partial b} (w^T x + b) = 1 \end{aligned}$$

לכן סה"כ נקבל

$$\begin{aligned} \frac{\partial \ell_i}{\partial w} &= \frac{p_i - y_i}{p_i(1 - p_i)} \cdot p_i(1 - p_i) \cdot x_i = (p_i - y_i)x_i \\ \frac{\partial \ell_i}{\partial b} &= \frac{p_i - y_i}{p_i(1 - p_i)} \cdot p_i(1 - p_i) \cdot 1 = p_i - y_i \end{aligned}$$

כלומר

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial w} &= \sum_{i=1}^N (p_i - y_i)x_i \\ \frac{\partial \mathcal{L}}{\partial b} &= \sum_{i=1}^N p_i - y_i \end{aligned}$$

ומכאן כלל העדכון לפי האלגוריתם יהיה

$$\begin{aligned} w &\leftarrow w - \eta \sum_{i=1}^N (p_i - y_i)x_i \\ b &\leftarrow b - \eta \sum_{i=1}^N p_i - y_i \end{aligned}$$

1.3 גבול ההחלטה.

גבול ההחלטה הוא כלל שלפיו אנחנו מחליטים מה יהיה הסיכוי של הדגימה לשנו.


על פניו ניכר כי כלל ההחלטה הוא מאוד פשוט: יש לנו מודל

$$p(x) = \frac{1}{1 + e^{-(w^T x + b)}}$$

שאומר לנו לכל דגימה x_i מה הסיכוי שהמחלקה שלה $y_i = 1$. בגישה הכי נאיבית, אם $p(x) \geq 0.5$, נסווג את הדגימה להיות 1, אחרת נסווג להיות 0. פרקטית, נקבל

$$y = 1 \iff p(x) \geq 0.5 \iff \frac{1}{1 + e^{-(w^T x + b)}} \geq 0.5 \iff w^T x + b \geq 0$$

גבול ההחלטה אצלנו הוא סקלר במקרה ש- x הוא סקלר, אבל במודלים אחרים הוא יכול להשתנות (לדוגמה ב-SVM הוא היפרמישור (נגיע בהמשך)).



אם לדוגמה אנחנו רוצים לסווג כ-1 רק דגימות שאנחנו ממש בטוחים לגביהן, אז לפי התמונה פה ניקח את גבול ההחלטה שלנו להיות 0.2 ואז הפעם נקבל

$$y = 1 \iff p(x) \geq 0.2 \iff \frac{1}{1 + e^{-(w^T x + b)}} \geq 0.2 \iff w^T x + b \geq -\ln 4$$

ובאופן כללי אם רוצים שגבול ההחלטה יהיה p אזי נקבל

$$y = 1 \iff \dots \iff w^T x + b \geq \ln \frac{p}{1-p}$$

כלומר בגדול רגרסיה לוגיסטית היא רגרסיה לינארית על ה- $\log \text{odds}$.

הערה 8.1. לגבול ההחלטה אנחנו קוראים גם threshold . יותר פרטים יבואו בפרק על הערכת המודל המסווג.

ככל שנגדיל את כמות המימדים ככה גם מימד גבול ההחלטה יגדל. זה נכון כי נדוגמה אם ניקח $x = (x_1, x_2, x_3)$ אזי המודל שלנו יהיה

$$p(x) = \frac{1}{1 + e^{-(w_1 x_1 + w_2 x_2 + w_3 x_3 + b)}}$$

ואם נקבע $\text{threshold} = p$ נקבל

$$y = 1 \iff \dots \iff w_1 x_1 + w_2 x_2 + w_3 x_3 + b \geq \ln \frac{p}{1-p}$$

כלומר נקבל שבעצם אנחנו רוצים לאמן "מישור מפריד" שיחלק לנו את שתי המחלקות. במימד גבוה הרעיון ישאר אותו דבר, אם יהיה לנו $x = (x_1, \dots, x_d)$ אז נרצה למצוא מישור $w^T x + b = 0$ שיפריד לנו בין שתי המחלקות באופן הכי טוב.


1.4 רגולריזציה.

אחרי שאימנו את המודל שלנו לפי

$$w \leftarrow w - \eta \sum_{i=1}^N (p_i - y_i) x_i$$

$$b \leftarrow b - \eta \sum_{i=1}^N p_i - y_i$$

אנחנו נשים לב לתופעה משונה, הפרמטרים θ שלנו נורא גדולים. למה בעצם זה קורה? אם θ זה הסט פרמטרים שמפריד לי את שתי המחלקות בצורה הכי טובה, אם ניקח $\theta' = 2\theta$ נקבל $\mathcal{L}$ נמוך יותר וזה הגיוני, כי ככל שהערכים של w, b גבוהים יותר, ככה הסיגמואיד שלנו יראה יותר ויותר כמו פונקציית מדרגה (כי $\sigma(\theta \cdot x) \xrightarrow{\theta \rightarrow \infty} \mathbb{I}_{x>0}(x)$), כמתואר בתרשים




מה למדנו לעשות כאשר אנחנו לא רוצים שהפרמטרים של המודל ישתוללו יותר מדי? נוכל לשים רגולריזציה! לפיכך ה- $loss$ שלנו יראה

$$\mathcal{L}(w, b) = \text{BCE}(w, b) + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$$

ושוב המקשולות שלנו לא ירצו לגדול פי $1e10$ לדוגמה בשביל לסחוט עוד שיפור של $3 - 1e$ ב- $loss$.

הערה 9.1. לכאורה זה נראה שגם w וגם b הם אלו שגורמים לסיגמואיד להתפוצץ ולהפוך לפונקציית מדרגה, אבל בתכלס כל מה ש- b עושה זה מזיז לי את הסיגמואיד ימינה/ שמאלה



לכן גם עכשיו הוא לא צריך להיכלל ברגולריזציה.