

מבוא לבניה מלאכותית - תרגול 4.

רגב יחזקאל אימרה.

29 בנובמבר 2025

רגולריזציה: *Standardization*.

אחרי שלמדנו על $l1/l2$ וכל שאר הרגולריזציות, עוד שיטה שמאוד מומלצת היא נירמול הדאטה: אנחנו רוצים להעביר את הדגימות שלנו x שיהיה להן ממוצע 0 ושונות 1, לכן נעביר

$$x_{scaled} = \frac{x - \mu}{\sigma}$$

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i \quad \text{ממוצע הדגימות ו-} \sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

עושים את זה כי יש אם כל הדאטה שלי ממש גדול, אם אני מזיז אותו שיהיה מרוכז סביב 0 יכול גם לחסוך לי בלשמור את כל הדגימות במחשב, וגם יהיה לי יותר קל ללמוד את ההתפלגות.


מיותר לציין שכאשר אנחנו משתמשים במודל, ננרמל את הדאטה לפי μ, σ שחישבנו על ה-*train set*.

1 *SVM* (מכונת וקטורים תומכים).

אנחנו ממשיכים עם סיווג בינארי של הדאטה שלנו. נניח הפעם אנחנו מדדנו עוד פעם את המשקל של עכברים כדי לסווג אותם כ"שמנים"/"לא שמנים" (בלי להעליב אף אחד) וקיבלנו את זה:




כשהנקודות האדומות הן עכברים לא שמנים והנקודות הירוקות הם העכברים השמנים. בהתבסס על הדגימות האלה אני יכול לקבוע ערך סף (*threshold*)




ככה שאם נדגום עכבר חדש עם פחות משקל מאשר הערך סף, נסווג אותו כתור לא שמן, וכשנשקול עכבר חדש עם יותר משקל מהערך סף, נסווג שהוא כן שמן.

אבל מה יקרה אם נדגום עכבר כזה:



כיוון שהמשקל שלו יותר גבוה מהערך סף, נסווג אותו כתור עכבר שלם, אבל זה לא הגיוני כל כך כי הוא הרבה יותר קרוב לעכברים הלא שמנים מאשר לעכברים השמנים, לכן המסקנה היחידה היא שהערך סף הזה גרוע. איך אנחנו יכולים להשתפר? אם נחזור לכל הדגימות שלנו, אנחנו יכולים להתמקד בדגימות שבקצה של כל אשכול ולהשתמש באמצע הקטע שהן יוצרות כתור ערך סף.



עכשיו כשנדגום את אותו עכבר ממקודם, המשקל שלו יהיה יותר קרוב לאלו שלא שמנים מאשר לאלו ששמנים, כלומר נסווג אותו כתור לא שמן.

הגדרה 1.1. המרחק הכי קצר בין הדגימות וה-*threshold* נקרא **שול** (*shul*, באנגלית - *margin*) (יש שול אחד כי עושים מינימום על מרחק שעל כל הדאטהסט, לא על קבוצה 0 בנפרד וקבוצה 1 בנפרד).


כיוון ששמנו את ה-*threshold* באמצע של שתי הדגימות "הכי קרובות", יוצא הוא המרחק של ה-*threshold* משתי נקודות. גם יוצא שבגלל שה-*threshold* בדיוק באמצע של שתי הנקודות האלו, השול הזה הכי גדול שהוא יכול להיות. אם לדוגמה נזיז את ה-*threshold* שמאלה, אז המרחק בינו לבין דגימה של עכבר לא שמן תהיה נמוכה יותר, כלומר השול יהיה נמוך יותר משהיה.

הגדרה 2.1. מסווג שנותן לנו את השול הכי גדול נקרא (למרבה ההפתעה) **מסווג השול המקסימלי** (*maximim margin classifier*).

שאלה 3.1. אבל מה עושים אם עכשיו היו לי דגימות כאלו:



זה אותם עכברים ממקודם פשוט שעכשיו הוספתי עוד עכבר שבטעות סיווגתי אותו להיות לא שמן כשבפועל הוא שמן. אם הייתי רוצה להתאים מסווג שול מקסימלי, אז ה-*threshold* באמת היה באמצע הדרך בין העכבר הלא שמן עם המשקל הגבוה ביותר ובין העכבר השמן עם המשקל הנמוך ביותר. הוא יהיה ממש קרוב לעכברים השמנים, אבל ממש ממש רחוק מהעכברים הלא שמנים, הכל בגלל שהוספתי *outlier* אחד בטעות. זה בעיה כי אם עכשיו יש לי עכבר חדש



אז באופן אוטומטי אני אסווג אותו כתור עכבר לא שמן, למרות שהוא קרוב יותר חקבוצת העכברים השמנים מאשר לאלו שלא שמנים. זה הופך את מודל מסווג השול המקסימלי למודל עלוב, כי הוא ממש רגיש ל-*outliers* ואני רוצה מודל שיהיה די אדיש אליהם (כי טעויות קורות ואני לא רוצה מודל שיהפוך לי לגרוע גם אם עשיתי טעות אחת על דאטה גדול).

כדי לשפר את המודל שלנו אנחנו חייבים לבחור *threshold* שיהיה אדיש ל-*outliers*, כלומר אנחנו חייבים להרשות שאולי בדאטה שלנו יש סיווגים לא נכונים. לדוגמה, אם נשים את ה-*threshold* בין הנקודה האדומה השנייה הכי ימנית לבין הנקודה הירוקה הכי שמאלית, נקבל שאכן יש לנו דגימה שסיווגנו לא נכון, אבל מצד שני המודל שלנו עכשיו מסווג באופן יותר הגיוני את אותה נקודה ממקודם, כי היא באמת קרובה יותר לעכברים השמנים, יותר מאשר העכברים הלא שמנים.

הגדרה 4.1. הפרדה לקבוצות שלא מרשה טעויות בסיווג נקראת **הפרדה קשיחה**. הפרדה לקבוצות שכן מרשה טעויות בסיווג נקראת **הפרדה רכה**.

שאלה 5.1. איך נסכם את זה במונחי $bias \setminus variance$?

- בסיווג קשיח, בחרנו *threshold* שרגיש לשגיאות ב-*training data* שלנו, כלומר היה לו *bias* נמוך (כי הוא לופד את השגיאות שלנו על ה-*train*), אבל היה לו *variance* גבוה כי בתפורה היה לו הרבה טעויות על דגימות חדשות, כלומר עשינו *overfit*.
- בסיווג רך, בחרנו *threshold* שפחות היה רגיש ל-*outliers* ב-*train* שלנו וכתוצאה מכך סיווג לא נכון חלק מהנקודות שלנו, היה לו *bias* נמוך (כי הוא למד פחות טוב על ה-*train* שלנו). מצד שני, כשהבאנו לו דגימות חדשות הוא כן ביווג אותן יותר טוב ממקודם, כלומר היה לו *variance* נמוך יותר.


הגדרה 6.1. שול שמתקבל כתוצאה מהפרדה רכה נקרא **שול רך**.

במרחק של שול רך מן ה-*threshold* שלנו אנחנו יכולים שיהיו לנו נקודות מהקבוצה שלנו, ואנחנו יכולים שיהיו לנו *outliers*. איך אנחנו יודעים כמה *outliers* אני מוכן לקבל? את זה נעשה בעזרת *cross-validation*, עוד פרטים בהמשך.

הגדרה 7.1. מסווג שמשמש בשול רק נקרא **מסווג שול רך** (באנגלית - *soft margin classifier*).

הגדרה 8.1. דגימות הנמצאות בתוך השול הרך נקראות **תומכים** (תומכים במה? מי יודע!).

אם עכשיו לכל עכבר אני מודד משקל וגובה, אני אקבל משהו כזה:



כאשר ציר ה- x הוא משקל וציר ה- y הוא גובה העכבר.

נאמן מסווג שול רך ונקבל את השול הרך האדום (אם אני מעליו אני לא שמן ואם אני מתחתיו אני כן שמן). השול הרך נמדד ביחס לשתי הנקודות המודגשות. הקווים הכחולים נותנים לנו מובן של כל הנקודות האחרות ביחס לשול הרך. כמו מקודם נשתמש ב-*cross-validation* ונקבל שלאפשר לנקודה האדומה שמתחת לשול להיות *outlier* יתן לנו סה"כ מודל טוב יותר.

הגדרה 9.1. מודל ה-*SVM* הוא מסווג לינארי מהצורה

$$f_{\theta}(x) = w^T x + b$$

שחזרה

$$\hat{y}_i = \text{sign}(w^T x_i + b)$$

כך שהמישור $w^T x + b = 0$ יביא את השול הכי גדול.

1.1 פונקציית $loss$?

נפרמל את הבעיה באופן מתמטי:

נניח שהדאטה שלנו פריד לינארית, אנחנו פשוט צריכים לבחור איזה ישר מפריד אנחנו רוצים. נסמן את קבוצת המחלקות להיות הפעם $\{-1, 1\}$ (יותר נוח למתמטיקה שתבוא), לכן אנחנו יכולים להניח שקיימים w, b כך שלכל דגימה (x, y) :

$$y(w^T x + b) > 0$$

כלומר אם $y = 1$ אז x מעל המישור המפריד, ואם $y = -1$ אז x מתחת למישור המפריד.

כאמור, יש ∞ מישורים מפרידים, אבל אנחנו רוצים לבחור את האחד הכי חזק, כלומר אנחנו רוצים את השול הכי גדול. נזכור כי המרחק מנקודה x למישור $w^T x + b = 0$ הוא

$$\frac{|w^T x + b|}{\|w\|}$$

(הנורמה היא נורמה אוקלידית כמובן, כלומר $\|\cdot\|_2$).

נחפש w, b שיקיימו לשני התומכים

$$y_i(w^T x_i + b) = 1$$

ולכן כל נקודה אחרת תביא לנו

$$y_i(w^T x_i + b) \geq 1$$

(כי התומכים הם הנקודות הכי קרובות לישר שלנו (אין *outliers* להזכירם כי הנחנו שהדאטה פריד לינארית). לפיכך השול הוא פשוט $\frac{1}{\|w\|}$ אז למקסם את השול זה שקול למזער את $\|w\|$. נכתוב כבעיית אופטימיזציה:

$$\begin{aligned} \min_{w, b} \frac{1}{2} \|w\|^2 \\ s.t. \ y_i(w^T x_i + b) \geq 1, \forall i \end{aligned}$$

זה המודל עבור ההפרדה הקשיחה.

הבעיה היא שלפעמים הדאטה שלנו לא פריד לינארית. נסמן $\xi_i \geq 0$ להיות כמה הדגימה ה- i רחוקה מהשול, לכן נוכל לכתוב את הבעיה כתור

$$\begin{aligned} \min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ s.t. \ y_i(w^T x_i + b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{aligned}$$

זה הופך לנו את הבעיה מהפרדה קשה להפרדה רכה. נשים לב כי אם באמת $y_i(w^T x_i + b) \geq 1$ אז $\xi_i = 0$ כי הנקודה מחוץ לשול, אם $0 < y_i(w^T x_i + b) < 1$ אז גם $0 < \xi_i < 1$ כי הנקודה בתוך השול, ואם $y_i(w^T x_i + b) \leq 0$ אז הנקודה היא *outlier* ו- $\xi_i \geq 1$. C כאן הוא כמו λ ברגולריזציה, C גבוה יעניש בחוזקה כל טעות והמודל יתאמץ הרבה כדי להקטין דווקא את השוליים - יכול לגרום ל-*overfit*. C קטן פחות ישנה לו טעויות פה ושם לכן המודל יעבוד פחות קשה בלהקטין את השוליים כדי להתאים את עצמו לדגימות העכשוויות - פחות *overfit*.

בדרך כלל אני עדיין ארצה להעניש את המודל שלי על ξ_i גדולים מדי, לכן נשתמש ב- $C = 1$. אם נחפש נוסחא ל- ξ_i נקבל

$$\xi_i = \max(0, 1 - y_i(w^T x_i + b))$$

אבל האילוצים מתקיימים אוטומטית כי

$$\begin{aligned} \xi_i = \max(0, 1 - y_i(w^T x_i + b)) &\Rightarrow \xi_i \geq 1 - y_i(w^T x_i + b) \Rightarrow y_i(w^T x_i + b) \geq 1 - \xi_i \\ &\Rightarrow \xi_i \geq 0 \end{aligned}$$

לכן נציב בחזרה בבעיית אופטימיזציה שלנו ונקבל שאנחנו מחפשים

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(w^T x_i + b))$$

זה ממש דומה כבר לפונקציית *loss*, לכן נגדיר:

הגדרה 10.1. נגדיר *hinge-loss* של בעיית ההפרדה הרכה להיות

$$Hinge(\theta) = \sum_{i=1}^N \max(0, 1 - y_i(w^T x_i + b))$$

$$\mathcal{L}(\theta) = \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(w^T x_i + b))$$

שאלה 11.1. למה אין לנו פקטור של $\frac{1}{N}$ מחוץ לסכום?

תשובה: אפשר לשים, היסטורית זה לא מה שעשו. אנחנו לא מסתכלים פה על הטעות הממוצעת, אנחנו סוכמים את ξ_i כדי להיפטר מהאילווצים. לטריק הזה קוראים "צורת אפיגרף". גם אם נשים $\frac{1}{N}$ לפני הסכום, C יאבד מכוחו ואז כדי שתהיה לו אותה עוצמה נצטרך להציב $C' = CN$.

שאלה 12.1. למה אנחנו תקועים עם פקטור של $\frac{1}{2}$ ולא נותנים לו להיות λ כללי?

תשובה: אנחנו לא תקועים איתו, בהתחלה הבעיה שלנו הייתה

$$\min_{w,b} \frac{1}{2}\|w\|^2$$

$$s.t. y_i(w^T x_i + b) \geq 1, \forall i$$

ואותו פקטור $\frac{1}{2}$ נשאר איתנו עד הסוף, לכן אפשרי לכתוב

$$\mathcal{L}(\theta) = \lambda\|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(w^T x_i + b))$$

פשוט יהיו לנו 2 היפרפרמטרים. היסטורית לפני האופטימונה שמו את הפקטור $\frac{1}{2}$ כדי שבגזירה יהיה משהו יפה $w = \frac{\partial}{\partial w} \frac{1}{2}\|w\|^2$, אבל באמת שאין לו חשיבות.

שאלה 13.1. האם אנחנו יכולים להוסיף $\lambda_1\|w\|_1$ לפונקציית ה- $loss$?

תשובה: כן, כמו ברגולריזציה רגילה, פשוט שאז זה לא יהיה $loss$ של SVM , ואם אנחנו מוסיפים את זה אז אי אפשר להפעיל את "תעלול הגרעין" (שנדבר עליו בהמשך).

שאלה 14.1. למה דווקא לסכום יש פקטור של C ולא ל- $\|w\|$ כמו ברגולריזציה רגילה?

תשובה: כי ברגולריזציה, הדבקנו היפרפרמטר על כל דבר שיכל "להתפוצץ ל- ∞ ", ופה כל ξ_i יכולים בהחלט להתפוצץ ל- ∞ אם נתאים מסווג גרוע.

שאלה 15.1. איך $\mathcal{L}(\theta) = \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(w^T x_i + b))$ הזה קשור ל- $\mathcal{L}(\theta) = - \sum_{i=1}^N \log \mathbb{P}(y_i|x_i; \theta)$ שהעגנו בחלק הקודם? הרי

אמרנו שזה מה שכל מודל רוצה למזער?

תשובה: הם לא קשורים. מודל רגרסיה מניח שהנקודות שלי באות מהתפלגות כלשהן, ולכן רוצה ללמוד אותן, אבל SVM הוא לא מודל הסתברותי, הוא מודל גאומטרי, שבא מהתבוננות בנקודות והרצון למצוא להם ישר מפריד עם השוליים הכי גדולים.

1.2 איך מאמנים?

כמובן שאנחנו יכולים להשתמש באלגוריתם מורד הגרדיאנט (כי הכל קמור ושאר התנאים שתראו בקורס "אופטימיזציה" מתקיימים), לכן נעשה כמו שעשינו ברגרסיה לוגיסטית ונסמן:

$$m_i = y_i(w^T x_i + b) \bullet$$

$$\ell_i = \max(0, 1 - m_i) \bullet$$

לכן ה- $loss$ הוא

$$\mathcal{L}(w, b) = \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \ell_i$$

ונשים לב כי את הסכום $\sum_{i=1}^N$ אפשר לכתוב גם כתור $\sum_{i \in I}$ כאשר $I = \{i : m_i < 1\}$ (כי אחרת $\ell_i = 0$), לכן עבור $i \in I$ יתקיים $\ell_i = 1 - m_i$

$$\frac{\partial}{\partial w} \frac{1}{2}\|w\|^2 = w$$

$$\frac{\partial}{\partial w} \ell_i = \frac{\partial}{\partial w} (1 - y_i(w^T x_i + b)) = -y_i x_i$$

ומכאן

$$\nabla_w \mathcal{L} = w - C \sum_{i \in I} y_i x_i$$

ולפי b נקבל

$$\frac{\partial}{\partial w} \ell_i = -y_i$$

$$\nabla_w \mathcal{L} = -C \sum_{i \in I} y_i$$

ומכאן שכללי העדכון יהיו

$$w \leftarrow (1 - \alpha)w + \alpha C \sum_{i \in I} y_i x_i$$

$$b \leftarrow b + \alpha C \sum_{i \in I} y_i$$

* אם $m_i = 1$ אז ניקח תת-גרדיאנט כלשהו, זה לא משנה כי מדובר בקבוצה ממידה 0.


2 $Kernel - SVM$ - כשהדאטה לא פריד לינארית.

באופן כללי אנחנו יכולים להסתפק פה במודל די סביר שמאפשר להתמודד עם *outliers*, אבל מה אם אני רוצה לסווג את הדאטה הבא:



שמתאר לי פציינטים שנרפאו ממחלה כתלות בכמה תרופה הבאתי להם? אם המינון נמוך מדי שום דבר לא יקרה, אם המינון רב מדי הם ימותו (או לא יבראו מסיבה פחות קיצונית), לכן צריך מינון מתאים כדי לסווג שחולה הבריא. לא משנה איפה נשים את ה-*threshold* שלנו, אף פעם לא יהיה לנו סיווג טוב כי הדאטה שלנו לא פריד לינארית! בשביל זה המציאו את המודל הבא:

אינטואיציה: בואו ניקח את החולים שלי שנתתי להם מינון של x מיליגרם מהתרופה שלי ונפרוש אותם על ציר ה- x שלי, ולכל חולה נחשב את המינון בריבוע x^2 של התרופה שהבאתי לו, ונשים את זה על ציר ה- y .



והפעם אני יכול להפריד את הדאטה שלי לינארית הרבה יותר בקלות!

נעביר קו מפריד ונסווג דגימה חדשה d לפי האם d^2 (הקואורדינטה ה"חדשה" שלה בציר ה- y) מעל הקו המפריד או לא.

הצעה 1.2. מכאן שהרעיון המרכזי מאחורי מודל ה- SVM הלא לינארי הוא:

1. להתחיל עם דאטה בפיצד נמוך (יחסית), ששם אי אפשר להפריד אותו לינארית.

2. להעביר את הדאטה לפיצד יותר גבוה (בצורה חכמה!).

3. למצוא פסווג לינארי שמפריד את הדאטה בפיצד הגבוה.

נניח שאנחנו רוצים להעביר את כל הדאטה שלנו לפי הכלל $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^D$, כאשר D יכול להיות גדול מאוד ביחד ל- d , אולי אפילו אינסופי. אזי נאמן את ה- SVM במימד החדש להיות

$$f_\theta(x) = w^T \phi(x) + b$$

והיופי פה זה שאם בחרתי את ϕ טוב, עכשיו אני באמת יכול להפריד את הדאטה שלי לפי $\hat{y}_i = f_\theta(x_i)$.

מה הבעיה פה?

כדי לחשב את $w^T \phi(x)$ אנחנו צריכים:

1. לחשב את $\phi(x)$ מלכתחילה.

2. לאכסן את $\phi(x)$ ואת w במחשב שלנו.

הבעיה היא שאם D שלי גדול, זה ממש בעייתי לי לשמור את שני הוקטורים הללו בזיכרון, וזה גם בעייתי לי להכפיל אותם כל הזמן כי זה נורא יקר חישובית.

לכן אנחנו צריכים לשכתב את המודל שלנו בצורה יותר חכמה.

אנחנו רוצים לפתור

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & y_i(w^T \phi(x_i) + b) \geq 1 - \xi_i, \forall i \\ & \xi_i \geq 0 \end{aligned}$$

לפי שיטת כופלי לגראנז' נגדיר את הלגראנז'אן להיות

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i (y_i (w^T \phi(x_i) + b) - 1 + \xi_i) - \sum_{i=1}^N \mu_i \xi_i$$

ורוצים למזער לפי w . לכן

$$\frac{\partial \mathcal{L}}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i \phi(x_i)$$

כלומר

$$w = \sum_{i=1}^N \alpha_i y_i \phi(x_i)$$

ומקבלים עוד דברים...

לכן נכתוב

$$\begin{aligned} f_\theta(x) &= w^T x + b = \left(\sum_{i=1}^N \alpha_i y_i \phi(x_i) \right)^T \phi(x) + b \\ &= \sum_{i=1}^N \alpha_i y_i \langle \phi(x_i), \phi(x) \rangle + b \end{aligned}$$

הגדרה 2.2. נגדיר את פונקציית הגרעין להיות $K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$ כלומר פונקציית הגרעין מחזירה את המכפלה הפנימית בין ϕ של x_i, x_j , אבל כפונקציה של x_i, x_j . לכן נוכל להמשיך לכתוב

$$f_\theta(x) = \sum_{i=1}^N \alpha_i y_i K(x_i, x) + b$$

והמסווג יהיה

$$\hat{y}_i = \text{sign} \left(\sum_{i=1}^N \alpha_i y_i K(x_i, x) + b \right)$$

שאלה 3.2. למה זה יותר טוב מאשר $\hat{y}_i = \text{sign}(w^T \phi(x_i) + b)$?

1. אנחנו לא מחשבים $\phi(x)$.
 2. לא שופרים את w בזיכרון.
 3. לעולם לא עובדים ב- $\mathbb{R}^D$.
 4. הפסווג תלוי בגרעין בלבד.
 5. גבול ההחלטה הוא לא לינארי בפרחב הפקורי.
- גרעינים שימושיים:
- גרעין פולינומיאלי

$$K(x, x') = (x^T x' + r)^d$$

הגרעין הכי פשוט שמביא לנו גבול ההחלטה לא לינארי.

- גרעין גאוסיאני (RBF)

$$K(x, x') = e^{-\gamma \|x - x'\|^2}$$

ממפה את הדאטה "למרחב ממימד אינסופי" ומביא גבול ההחלטה לא לינארי.

- גרעין סיגמואידלי

$$K(x, x') = \tanh(\gamma x^T x' + r)$$

אם אנחנו רוצים לבנות $kernel$ משלנו, זה מאוד פשוט.

הגדרה 4.2. פונקציה $K : X \times X \rightarrow \mathbb{R}$ תיקרא **גרעין** אם היא:

1. סימטרית: $K(x, z) = K(z, x)$ לכל $x, z \in X$.

2. חיובית: במובן שלכל $x_1, \dots, x_n \in X$ קבוצה סופית מתקיים

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0$$

לכל $c_i \in \mathbb{R}$

הערה 5.2. הגרעין הסינגמואידי אינו גרעין!