

מבוא לבנינה מלאכותית - תרגול 7.

רגב יחזקאל אימרה.


5 בינואר 2026

חלק I


רשתות נוירונים.

1 הגדרות, אינטואיציה.

ראינו כבר שאנחנו יכולים להשתמש במבנה מודל לינארי עבור סיווג/ רגרסיה. עבור מודל רגרסיה לדוגמה היה לנו $y_i = Wx_i + b$, שזה נראה ככה:



ועבור מודל סיווג היה לנו (במולטיקלאס):



כאשר כל קשת בין *input node* ל-*output node* היא משקולת w_{ij} . נרצה לפרמל קצת את המודל:
הגדרה 1.1. נוירון זה פונקציה המחשבת סכום ממושקל של כל הקלטים שלה, ואז מפעיל פונקציה f על הסכום הממושקל. במתמטית, נוירון הוא בדיוק

$$y = f(Wx + b)$$

הגדרה 2.1. f זהו נקראת **פונקציית אקטיבציה**.

הגדרה 3.1. רשת נוירונים זה פונקציה המקבלת קלט, ומעבירה אותו דרך הרבה נוירונים לצורך הוצאת פלט מסוים. גם מודל הסיווג וגם מודל הרגרסיה הם מודלים של רשתות נוירונים, ואת שניהם אפשר לסכם במשוואה

$$y = f(Wx + b)$$

על ידי בחירת f ומימדים מתאימים של W המתאימים לבעיה.


הגדרה 4.1. שכבה של נוירונים נקראת **layer**.

הגדרה 5.1. הקלט של רשת נוירונים נקרא **input layer**. הפלט של רשת נוירונים נקרא **output layer**.

הגדרה 6.1. כל שכבה של רשת נוירונים שהיא לא **input layer** \ **output layer** נקראת **hidden layer**.

נשאלת השאלה, מה אם אני רוצה מודל יותר חזק?

נשאלת השאלה, למה המודל שלנו לא חזק כבר עכשיו. התשובה היא, שה- **output layer** הוא פשוט צירוף לינארי $y = Wx + b$ של כל ה- **input layer**, לדוגמה $y = 2x_1 - 0.7x_2 + 0.2x_3$, שאת זה אנחנו כבר מכירים. מה אם לדוגמה, אני ארצה לתת משקל לא רק ל- x_1 , אלא ל- $3x_1 - 2x_2$? פה במודל הפשוט שלנו אין לנו איך לעשות את זה, כיוון שיש לנו צירוף לינארי של ה- **input layer**, ואנחנו רוצים צירוף לינארי שלהם. אז מה הפתרון? אפשר להוסיף עוד שכבה באמצע, שהיא תעזור לנו לחשב צירופים לינארים של ה- **input layer**, ואז נחשב צירופים לינארים ממנה!



עכשיו בעזרת ה- **hidden layer** אנחנו יכולים לתאר את התהליך שלנו ב-2 שלבים:

$$h = f(W^1 x + b^1)$$

$$y = f(W^2 h + b^2)$$

או פשוט

$$y = f(W^2 f(W^1 x + b^1) + b^2)$$

נשאלת השאלה, מי זו f הזו? מה אנחנו רוצים ממנה?

שאלה 7.1. האם f יכולה להיות $f(x) = x$?

תשובה: לא! אחרת המודל שלנו היה קורס להיות שכבה אחת

$$y = f(W^2 f(W^1 x + b^1) + b^2) = \underbrace{W^2 W^1}_{=W} x + \underbrace{W^2 b^1 + b^2}_{=b} = Wx + b$$

באותו אופן f לא יכולה להיות פונקציה לינארית, כיוון שאז עוד פעם המודל היה קורס להיות מודל לינארי:

$$f(x) = Ax + B \Rightarrow y = f(W^2 f(W^1 x + b^1) + b^2) = \dots W' x + b'$$

כלומר y כפונקציה של x היה שוב פעם בצורה מישורית, ואת זה אנחנו יודעים לעשות מעולה בלי קשר לשכבות ונוירונים. לכן אנחנו ניקח את f שלנו להיות פונקציה **לא לינארית**, על מנת שלא נוכל לצמצם את y להיות $y = \bar{W}x + \bar{b}$.

מעולה, עכשיו אנחנו יודעים לבנות מודל חזק יותר באמצעות 2 שכבות, ובאותו אופן אני יכול להגדיל את המודל שלי עד ω שכבות (ω הכוונה כל כמות סופית, אך ללא חסם עליון). ככה אני יכול ליצור ארכיטקטורות מסובכות כמו


$$h^1 = f(W^1 x + b^1)$$

$$h^i = f(W^i h^{i-1} + b^i)$$

$$y = f(W^k h^{k-1} + b^k)$$

עבור $i \in \{2, \dots, k-1\}$, כלומר הגדרנו פה רשת עם $k-2$ שכבות. בעצם הרעיון הוא שככל שאנחנו מגדילים את מספר השכבות, ככה אנחנו נותנים לרשת שלנו ללמוד יותר קשרים לא רק כפונקציה של הפיצ'רים, אלא גם קשרים בין הפיצ'רים (אולי לסכום $6x_1 - 0.7x_2$ יותר טוב מאשר פשוט wx_1).

דוגמה 8.1. נתונה רשת נוירונים הבאה:



עם פונקציית האקטיבציה $\sigma(x) = \frac{1}{1+e^{-x}}$ חשבו מה יהיה הפלט של הרשת.
פתרון. נחשב את הערך הראשון:

$$\begin{aligned} 1 \cdot 0.8 + 1 \cdot 0.2 &= 1 \Rightarrow \sigma(1) = 0.73 \\ 1 \cdot 0.4 + 1 \cdot 0.9 &= 1.3 \Rightarrow \sigma(1.3) = 0.78 \\ 1 \cdot 0.3 + 1 \cdot 0.5 &= 0.8 \Rightarrow \sigma(0.8) = 0.68 \end{aligned}$$

וכדי לחשב את הפלט:

$$0.73 \cdot 0.3 + 0.78 \cdot 0.5 + 0.68 \cdot 0.9 = 1.221 \Rightarrow \sigma(1.221) = 0.77$$

זה הפלט של הרשת.

2. Back – propagation

עכשיו בעצם כשיש לנו מודל שאנחנו יודעים לעבוד איתו, נשאלת השאלה החשובה – איך מאמנים אותו?
 נניח יש לי רשת מהצורה

$$\begin{aligned} h_1 &= f(W_1x + b_1) \\ h_2 &= f(W_2h_1 + b_2) \\ \hat{y} &= f(W_3h_2 + b_3) \\ L &= \text{Loss}(\hat{y}) \end{aligned}$$

אז בעצם יוצא שצריך לחשב את

$$\frac{\partial L}{\partial W_1}, \frac{\partial L}{\partial W_2}, \frac{\partial L}{\partial W_3}, \frac{\partial L}{\partial b_1}, \frac{\partial L}{\partial b_2}, \frac{\partial L}{\partial b_3}$$

אבל לדוגמה לחשב את $\frac{\partial L}{\partial b_1}$ זה מאוד בעייתי כי זה שקול לחשב את

$$\frac{\partial}{\partial b_1} \text{Loss}(f(W_3f(W_2f(W_1x + b_1) + b_2) + b_3))$$

ועבור רשתות עם יותר שכבות צריך לגזור דברים הרבה יותר מסובכים...

שאלה 1.2. איך אפשר לייעל את התהליך של חישוב הנגזרות החלקיות?


פתרון. בעזרת שימוש בכלל השרשרת!

במקום שכדי לחשב את $\frac{\partial L}{\partial b_1}, \frac{\partial L}{\partial b_2}$ אני אחשב את הכל מהתחלה, אני יכול לכתוב

$$\begin{aligned} \frac{\partial L}{\partial b_2} &= \frac{\partial L}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial h_2} \frac{\partial h_2}{\partial b_2} \\ \frac{\partial L}{\partial b_1} &= \frac{\partial L}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial h_2} \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial b_1} \end{aligned}$$

והפלא ופלא, קיבלנו בשני המקרים האלה שיש גורם משותף של $\frac{\partial L}{\partial \hat{y}}, \frac{\partial \hat{y}}{\partial h_2}$, לכן אם נשמור בצד את $\frac{\partial L}{\partial \hat{y}}, \frac{\partial \hat{y}}{\partial h_2}$, החישובים של הנגזרות יקחו פחות זמן.

דוגמה 2.2. עבור הרשת הזאת:



הניחו כי כל האקטיבציות הן $f(x) = \sigma(x) = \frac{1}{1+e^{-x}}$. בצעו מעבר *forward*, עדכנו את כל המשקולות של הרשת (מעבר *backward*), ואז בצעו עוד מעבר *forward*. הניחו כי $y = 0.5$, קצב הלמידה הוא 1, וכן $Loss = y - O_5$. פתרון. לפי ההגדרה של נוירון בודד, נקבל

$$H_3 = \sigma(x_1 w_{13} + x_2 w_{23}) = \sigma(0.35 \cdot 0.1 + 0.9 \cdot 0.8) = \sigma(0.755) = 0.68$$

באותו אופן

$$H_4 = \sigma(x_1 w_{14} + x_2 w_{24}) = \sigma(0.35 \cdot 0.4 + 0.9 \cdot 0.6) = \sigma(0.68) = 0.66$$

לכן

$$O_5 = \sigma(H_3 w_{35} + H_4 w_{45}) = \sigma(0.68 \cdot 0.3 + 0.66 \cdot 0.9) = \sigma(0.798) = 0.69$$

כלומר הפלט של הרשת הוא 0.69. לכן נקבל $Loss = 0.5 - 0.69 = -0.19$. כדי לחשב את הנגזרות:

$$\frac{\partial Loss}{\partial O_5} = -1$$

$$\frac{\partial O_5}{\partial w_{i5}} = H_i \sigma(H_3 w_{35} + H_4 w_{45}) (1 - \sigma(H_3 w_{35} + H_4 w_{45})) = H_i O_5 (1 - O_5) \quad i \in \{3, 4\}$$

$$\frac{\partial O_5}{\partial H_i} = w_{i5} \sigma(H_3 w_{35} + H_4 w_{45}) (1 - \sigma(H_3 w_{35} + H_4 w_{45})) = w_{i5} O_5 (1 - O_5) \quad i \in \{3, 4\}$$

$$\frac{\partial H_i}{\partial w_{ji}} = x_j \sigma(x_1 w_{1i} + x_2 w_{2i}) (1 - \sigma(x_1 w_{1i} + x_2 w_{2i})) = x_j H_i (1 - H_i) \quad i \in \{3, 4\}, j \in \{1, 2\}$$

מכאן נקבל לפי כלל השרשרת

$$\begin{aligned} \frac{\partial Loss}{\partial w_{35}} &= \frac{\partial Loss}{\partial O_5} \frac{\partial O_5}{\partial w_{35}} = -H_3 O_5 (1 - O_5) \\ \frac{\partial Loss}{\partial w_{45}} &= \frac{\partial Loss}{\partial O_5} \frac{\partial O_5}{\partial w_{45}} = -H_4 O_5 (1 - O_5) \\ \frac{\partial Loss}{\partial w_{13}} &= \frac{\partial Loss}{\partial O_5} \frac{\partial O_5}{\partial H_3} \frac{\partial H_3}{\partial w_{13}} = -w_{35} O_5 (1 - O_5) x_1 H_3 (1 - H_3) \\ \frac{\partial Loss}{\partial w_{23}} &= \frac{\partial Loss}{\partial O_5} \frac{\partial O_5}{\partial H_3} \frac{\partial H_3}{\partial w_{23}} = -w_{35} O_5 (1 - O_5) x_2 H_3 (1 - H_3) \\ \frac{\partial Loss}{\partial w_{14}} &= \frac{\partial Loss}{\partial O_5} \frac{\partial O_5}{\partial H_4} \frac{\partial H_4}{\partial w_{14}} = -w_{45} O_5 (1 - O_5) x_1 H_4 (1 - H_4) \\ \frac{\partial Loss}{\partial w_{24}} &= \frac{\partial Loss}{\partial O_5} \frac{\partial O_5}{\partial H_4} \frac{\partial H_4}{\partial w_{24}} = -w_{45} O_5 (1 - O_5) x_2 H_4 (1 - H_4) \end{aligned}$$

$$\begin{aligned}\frac{\partial Loss}{\partial w_{35}} &= -0.145 \\ \frac{\partial Loss}{\partial w_{45}} &= -0.141 \\ \frac{\partial Loss}{\partial w_{13}} &= -0.00488 \\ \frac{\partial Loss}{\partial w_{23}} &= -0.012 \\ \frac{\partial Loss}{\partial w_{14}} &= -0.015 \\ \frac{\partial Loss}{\partial w_{24}} &= -0.389\end{aligned}$$

נזכור כי כלל העדכון של כל פרמטר עם GD הוא

$$w \leftarrow w - \eta \frac{\partial Loss}{\partial w}$$

ונזכור כי $\eta = 1$, לכן נעדכן את הפרמטרים שלנו לפי

$$\begin{aligned}w_{35} &= 0.3 - (-0.145) = 0.445 \\ w_{45} &= 0.9 - (-0.141) = 1.041 \\ w_{13} &= 0.1 - (-0.005) = 0.105 \\ w_{23} &= 0.8 - (-0.012) = 0.812 \\ w_{14} &= 0.4 - (-0.015) = 0.415 \\ w_{24} &= 0.6 - (-0.389) = 0.989\end{aligned}$$

נעשה עוד מעבר $forward$:

$$\begin{aligned}H_3 &= \sigma(x_1 w_{13} + x_2 w_{23}) = \sigma(0.35 \cdot 0.105 + 0.9 \cdot 0.812) = \sigma(0.768) = 0.68 \\ H_4 &= \sigma(x_1 w_{14} + x_2 w_{24}) = \sigma(0.35 \cdot 0.415 + 0.9 \cdot 0.989) = \sigma(1.035) = 0.74\end{aligned}$$

וכן

$$O_5 = \sigma(H_3 w_{35} + H_4 w_{45}) = \sigma(0.68 \cdot 0.445 + 0.74 \cdot 1.041) = \sigma(1.073) = 0.745$$

כלומר $\eta = 1$ גרם לנו לחזות משהו יותר גרוע.

שאלה 3.2. מדוע זה קרה?

תשובה: זה בגלל שלקחנו $Loss$ להיות פונקציה שיכולה להחזיר לנו ערכים שליליים, כלומר בעדכון של ה- GD אנחנו עלינו בכיוון הגרדיאנט במקום לרדת בכיוון הגרדיאנט.

שאלה 4.2. אם היינו מחליפים את $Loss = y - O_5$ להיות $Loss = (y - O_5)^2$, האם היינו צריכים לחזור על כל החישובים שלנו מההתחלה (בחישובים הכוונה היא $forward \rightarrow backward \rightarrow forward$)?

תשובה: לא! תחילה, כל ה- $forward$ הראשון היה השאר אותו הדבר. שנית, בחישובים של הנגזרות, היינו צריכים רק לחשב מחדש את $\frac{\partial Loss}{\partial O_5}$. כמובן שזה היה מביא לנו סט חדש של פרמטרים במעבר ה- $backward$, ומכאן גם ה- $forward$ השני יהיה שונה.